

Análisis de la Red Facebook WOSN Wall

Francisco Vera - Felipe Subiabre - Benjamin Gonzalez

8 de julio de 2026

P1. Elección y descripción de la red

Para este análisis, se ha seleccionado la red "**facebook-wosn-wall**" obtenida del repositorio KONECT.

- **Nodos:** Representan usuarios dentro de un subconjunto de la red social Facebook.
- **Aristas:** Son dirigidas y representan una publicación (*post*) que un usuario origen hace en el muro de un usuario destino.

Elegimos analizar la red de interacciones en muros de Facebook por tres razones principales y prácticas:

1. **Mide interacción real, no solo amistades:** En las redes sociales, tener a alguien en la lista de amigos es un vínculo estático (pasivo). Sin embargo, tomarse el tiempo de publicar en el muro de otra persona demuestra un interés activo. Esto hace que la red sea un reflejo mucho más fiel de la verdadera influencia y atención en la comunidad.
2. **Se adapta perfectamente a PageRank:** El algoritmo fue creado para rastrear cómo la importancia fluye en la web a través de enlaces. En este caso, cada publicación en un muro funciona exactamente como un "enlace" que transfiere popularidad de un usuario a otro, haciendo que el modelo encaje de forma natural.
3. **Presenta un desafío técnico interesante:** Al explorar los datos, notamos que casi el 10% de los usuarios son "nodos colgantes" (reciben mensajes, pero no le escriben a nadie más). Esto nos da la oportunidad perfecta para poner a prueba la corrección matemática de la Matriz de Google y demostrar cómo evita que el cálculo se estanque.

Estadísticas básicas de la red

Cuadro 1: Estadísticas generales del dataset.

Métrica	Valor
Número de nodos	46,952
Número de aristas	274,086
Grado de entrada medio	5.8376
Grado de salida medio	5.8376
Nodo de mayor grado de entrada	2,420
Grado de entrada del nodo anterior	199
Densidad $\frac{m}{n(n-1)}$	0.00012433
Cantidad de nodos colgantes	4,562
Fracción de nodos colgantes	0.0972

P2: Pregunta e hipótesis inicial

- **Pregunta inicial:** ¿Qué usuarios dentro de esta red de Facebook actúan como los principales focos de atención e influencia comunitaria, y en qué medida su importancia está dictada únicamente por el volumen total de publicaciones que reciben en sus muros?
- **Hipótesis:** Se espera que los nodos (usuarios) con un grado de entrada elevado obtengan un PageRank alto, dado que recibir muchas publicaciones suele ser un indicador de popularidad.

Pero debido a la dinámica recursiva de las redes sociales, formulamos la hipótesis de que existirán usuarios con un grado de entrada moderado que alcanzarán un PageRank sobresaliente al ser contactados (enlazados) por perfiles altamente estratégicos o centrales.

P3: Análisis exploratorio de la red

El análisis preliminar revela que las distribuciones de grado (tanto de entrada como de salida) siguen una estructura típica de las **redes libres de escala (ley de potencias)**, donde la gran mayoría de los usuarios interactúa poco, mientras que un grupo selecto de usuarios concentra la mayor parte de la actividad.




Figura 1: Distribución de grado de entrada y salida en la red.




Figura 2: Comparativa del Top 10 de usuarios según su grado.

Nodos colgantes

Se identificaron **4,562 nodos colgantes** (el 9.72 % de la red). La presencia de estos nodos (que no publican en el muro de nadie más) es problemática porque actúan como “sumideros” en una marcha aleatoria, provocando que la matriz de hipervínculos tenga columnas de ceros. Esto rompe la propiedad estocástica necesaria para que el modelo converja de manera adecuada. La solución teórica aplicada consiste en reemplazar estas columnas nulas por el vector de distribución uniforme para construir la matriz estocástica S .

- **Cantidad de nodos colgantes (grado de salida = 0):** 4,562
- **Fracción del total de nodos:** 9.72 %
- **Ejemplos de nodos colgantes (primeros 10):** ['8', '18', '26', '42', '67', '126', '131', '141', '145', '152']

Conexidad

La red no es fuertemente conexa (posee 15,142 componentes fuertemente conexas y 1,981 componentes débilmente conexas). Esto no impide el cálculo, ya que el algoritmo PageRank introduce el parámetro de teletransporte para garantizar una matriz irreducible independientemente de la estructura subyacente.

Cuadro 2: Top 10 nodos de mayor grado de entrada.

Nodo	Grado de Entrada
2420	199
5706	161
7308	154
2611	150
2616	150
21015	147
6700	145
6765	145
9300	129
5684	120

P4: Construcción de la Matriz de Google

La Matriz de Google se define matemáticamente en tres fases implementadas en el código:

1. **Matriz de hipervínculos (H):** Contiene la probabilidad inicial de transición basándose únicamente en la red. Si el nodo j no es colgante, la columna reparte equitativamente la probabilidad entre sus enlaces salientes, por lo que suma 1. Si es colgante, la columna está compuesta por ceros.
2. **Matriz column-estocástica (S):** Repara los nodos colgantes. Cuando un usuario no hace publicaciones a otros (su columna en H es 0), se asume que puede saltar aleatoriamente a cualquier otro usuario. Se repara sumando probabilidad uniforme mediante el vector indicador.
3. **Matriz de Google (G):** Se define formalmente como:

$$G = \alpha \cdot S + \frac{(1 - \alpha)\mathbf{1}\mathbf{1}^T}{n}$$

Justificación de α : Utilizamos $\alpha = 0,85$, el estándar de la literatura, que asume que el agente tiene un 85 % de probabilidad de seguir la estructura de la red y un 15 % de teletransportarse aleatoriamente. Al sumar el término de teletransporte, garantizamos que todas las entradas de la matriz sean estrictamente positivas ($G > 0$). Por el **Teorema de Perron-Frobenius** (toda matriz no negativa e irreducible tiene un valor propio dominante positivo y un vector propio asociado con todas sus componentes positivas), esto asegura la existencia de un único vector propio dominante y positivo.

P5: Cálculo del PageRank mediante iteración de potencias

Comenzando con un vector uniforme $r^{(0)} = \frac{1}{n}$, el algoritmo alcanzó la convergencia (definida bajo la norma $L_1 < 10^{-10}$) en **114 iteraciones**.




Figura 3: Curva de convergencia del error en la iteración de potencias.

Propiedades garantizadas:

- Se verificó que $\|r^*\|_1 = 1$, lo que significa que el vector de PageRank es una distribución de probabilidad válida donde no hay fugas de masa.
- Se verificó que $r_i^* > 0$ para todos los nodos. Ningún usuario tiene influencia absoluta de “cero” gracias a la naturaleza irreducible de G .

Cuadro 3: Top 20 Nodos de mayor PageRank.

Rango	Nodo / ID	PageRank	In-degree	Out-degree
1	16177	$6,011973 \times 10^{-4}$	30	1
2	272	$4,555419 \times 10^{-4}$	31	1
3	6716	$4,343513 \times 10^{-4}$	48	1
4	10410	$4,191646 \times 10^{-4}$	24	1
5	2420	$3,472436 \times 10^{-4}$	199	115
6	4211	$3,424438 \times 10^{-4}$	23	1
7	3361	$3,330337 \times 10^{-4}$	119	52
8	7308	$3,242477 \times 10^{-4}$	154	124
9	9300	$3,229802 \times 10^{-4}$	129	88
10	15719	$3,139392 \times 10^{-4}$	14	1
11	26171	$2,943829 \times 10^{-4}$	98	0
12	2611	$2,937524 \times 10^{-4}$	150	115
13	425	$2,803480 \times 10^{-4}$	109	90
14	21513	$2,765703 \times 10^{-4}$	103	90
15	2712	$2,712635 \times 10^{-4}$	117	46
16	21015	$2,623360 \times 10^{-4}$	147	40
17	7580	$2,615393 \times 10^{-4}$	15	1
18	13204	$2,577926 \times 10^{-4}$	21	1
19	5706	$2,563298 \times 10^{-4}$	161	60
20	2311	$2,532964 \times 10^{-4}$	76	44

P6: PageRank vs. grado de entrada




Figura 4: Gráfico de dispersión: Grado de entrada vs. puntuación PageRank.

Existe una correlación de Pearson positiva de **0.817** entre el grado de entrada y el PageRank. Esto indica una tendencia general donde recibir más publicaciones aumenta la influencia del nodo. Sin embargo, el comportamiento divergente es crucial para entender el valor del PageRank:

- **Nodo 3130:** Tiene un grado de entrada relativamente alto para el conjunto de la red (15, puesto 4,614 de 46,952, pero su PageRank es muy bajo ($1,839 \times 10^{-5}$, puesto 19,190). Esto ocurre porque recibe interacciones de usuarios que, a su vez, tienen muy poca influencia en la red general (nodos periféricos).
- **Nodo 39260:** Posee un grado de entrada mínimo (1, puesto 39,282, es decir, casi al final de la red), pero alcanza un PageRank comparativamente alto ($9,032 \times 10^{-5}$, puesto 647). La única publicación que recibió en su muro proviene de un usuario altamente influyente, lo cual “transfirió” esa influencia hacia él.

P7: Interpretación de resultados

Al analizar los resultados del Top 20 en contexto observamos que las puntuaciones más altas recaen sobre los nodos **16177**, **272**, **6716** y **10410** (puestos 1 a 4). Llama la atención que sus grados de entrada (entre 24 y 48) son considerablemente menores que el del nodo con mayor grado absoluto de la red (2420, con 199 publicaciones recibidas), el cual queda en el puesto 5 del ranking de PageRank.

Esto significa que estos 4 usuarios no destacan por el volumen bruto de publicaciones que reciben, sino porque quienes les escriben en el muro son perfiles con una influencia muy alta dentro de la red. Basicamente usuarios altamente activos y conectados en múltiples círculos dentro del conjunto de Facebook.




Figura 5: Visualización del subgrafo del núcleo denso de usuarios en Facebook.

La visualización del subgrafo ilustra que entre ellos destacan algunos nodos puente (2420, 2611, 425 y 7308) que conectan comunidades que de otro modo quedarían prácticamente separadas. Además, los nodos con mayor Page Rank no siempre coinciden con los principales conectores estructurales, como 16177 o 10410 que son muy influyentes dentro de sus comunidades.

No es posible sectorizar por demografía u otros factores debido a los datos disponibles del dataset, pero se puede ver que se forman varios grupos de comunidades.

P8: Discusión, limitaciones y conclusiones

Comparación de resultados con la hipótesis inicial.

La hipótesis inicial se cumplió exitosamente. Tal como esperábamos, los nodos con mayores interacciones mostraron en general altos niveles de relevancia (correlación de Pearson de 0.817 entre grado de entrada y PageRank), pero las divergencias comprobadas (como el Nodo 39260, con un solo enlace entrante pero un PageRank que lo ubica en el puesto 647 de 46,952) demostraron matemáticamente que el PageRank evalúa la calidad y el peso específico del enlace, no solo la cantidad bruta.

Límites del PageRank y la red elegida.

- **Modelo de marcha aleatoria:** Puede resultar limitante en una red social. Un individuo navegando por los muros de Facebook rara vez realiza un “salto aleatorio” (teletransporte) a un extraño total con la misma probabilidad; la navegación suele estar sesgada por amistades y recomendaciones del algoritmo.
- **Nodos colgantes:** Un 9.72 % es una fracción considerable, lo que obliga a la matriz a redistribuir bastante probabilidad. Esto empuja ligeramente los perfiles hacia una media que podría alterar sutilmente el ranking de nodos intermedios.
- **Baja densidad de la red:** La baja densidad de una red reduce drásticamente la informatividad de PageRank, provocando que las puntuaciones de los nodos tiendan a homogeneizarse

Nuevas preguntas surgidas del analisis.

El análisis da nuevas interrogantes: ¿Están estos usuarios “top” vinculados a grupos organizados específicos? ¿Cómo afectaría la inclusión de datos temporales (*timestamps*) a este PageRank para crear una medida de “influencia en tiempo real”?

Explicación para persona sin conocimientos técnicos.

“Imagina que queremos encontrar a la persona más influyente en un colegio. Contar a cuántos chicos les cae bien una persona es útil, pero no es suficiente. Lo que de verdad te hace influyente es que **los chicos que ya son populares** se fijen en ti. Si te integras en el grupo de los más respetados, tú mismo adquieres ese respeto de forma inmediata, aunque en total no te conozca tanta gente de fuera. Nuestra fórmula matemática hizo exactamente eso: identificó a los verdaderos pilares de la red en Facebook premiando la calidad de las interacciones, no solo la cantidad.”

Repositorio del Proyecto

El código fuente y los datos están disponibles en:
<https://github.com/wbguc/Proyecto-Algebra2>