



Proyecto 2: PageRank sobre redes reales

Profesor: Felipe Urrutia
Ayudante: Luis Castillo

Objetivo

En este proyecto aplicarán el algoritmo PageRank a una red real obtenida de KONECT (<http://konect.cc>). La meta es formular una pregunta concreta sobre la red elegida, construir la Matriz de Google, calcular PageRank mediante iteración de potencias, e interpretar los resultados en el contexto del problema original.

Indicaciones generales

- **Grupos:** El proyecto se realiza en grupos de **2 o 3 estudiantes**.
- **Red:** Cada grupo debe elegir una red. La red debe ser **dirigida**, tener al menos **500 nodos** y **2 000 aristas**, y tener un contexto interpretable (no usar redes sintéticas ni redes sin descripción).
- **Código:** El código debe quedar en un repositorio público de GitHub. El repositorio debe incluir instrucciones de ejecución, enlace a los datos y los archivos necesarios para reproducir figuras y resultados.
- **Informe:** Se debe entregar un informe final en formato **.pdf**. El informe debe ser breve, claro y bien estructurado. Puede escribirse en Overleaf o en otra herramienta.
- **Fechas:** La publicación del proyecto corresponde a la semana 16 del curso. La entrega corresponde a la semana después del examen del curso.

Herramientas esperadas

Python debiera ser el lenguaje principal del proyecto. Una combinación razonable de librerías es:

- **numpy** y **scipy** para álgebra lineal y operaciones vectoriales;
- **scipy.sparse** para representar la matriz de hipervínculos en formato disperso;
- **networkx** para construcción del grafo y cálculo de métricas de red;
- **matplotlib** o **seaborn** para visualizaciones;
- **urllib** o **requests** para descargar el dataset directamente desde KONECT.



Pueden trabajar en Google Colab o en un notebook de Jupyter local. Lo importante es que el código sea fácil de ejecutar y reproducir.

Uso de herramientas de IA

Pueden usar herramientas como GitHub Copilot, Codex, ChatGPT u otras similares para apoyar el desarrollo. Su uso es permitido, pero ustedes siguen siendo responsables del contenido entregado. Deben entender el código que usan, revisar y corregir errores, verificar los resultados y escribir un informe que refleje comprensión real del análisis matemático.

Descripción del proyecto

PageRank es un algoritmo de ranking sobre grafos dirigidos que asigna a cada nodo una puntuación de importancia basada en la estructura de los enlaces que recibe y en quiénes lo enlazan.

La idea central es modelar una *marcha aleatoria* (Random Walk): un agente que recorre la red siguiendo aristas al azar, con una probabilidad α de seguir un enlace real y una probabilidad $1 - \alpha$ de saltar a cualquier nodo uniformemente. El PageRank de un nodo es la «fracción de tiempo» que esta marcha pasa en él a largo plazo, es decir, la distribución estacionaria de la Matriz de Google:

$$G = \alpha S + \frac{1 - \alpha}{n} \mathbf{1}\mathbf{1}^T,$$

donde S es la versión column-estocástica de la matriz de hipervínculos H , n es el número de nodos y $\alpha \approx 0,85$ es el factor de amortiguamiento.

El cálculo del PageRank se obtiene resolviendo el problema de eigenvalor $G\mathbf{r} = \mathbf{r}$ mediante iteración de potencias:

$$\mathbf{r}^{(k+1)} = G\mathbf{r}^{(k)}, \quad k = 0, 1, 2, \dots$$

En clases vimos que la convergencia está garantizada porque G es ergódica (irreducible y aperiódica).

P 1 (Elección y descripción de la red). Elijan una red dirigida de KONECT (<http://konect.cc>) con al menos 500 nodos y 2000 aristas. La red debe tener un contexto real e interpretable. Algunos ejemplos de redes disponibles en KONECT son redes de hipervínculos entre páginas web, redes de citación entre artículos científicos, etc. El catálogo completo está en <http://konect.cc/networks/>.

Describan la fuente de los datos: qué representan los nodos, qué representan las aristas, en qué contexto fue recopilada la red y por qué la eligieron. Incluyan una tabla con al menos las siguientes estadísticas básicas de la red: número de nodos n , número de aristas m , grado de entrada medio $\bar{d}^{\text{in}}$, grado de salida medio $\bar{d}^{\text{out}}$, nodo de mayor grado de entrada, densidad de la red $m/(n(n-1))$, cantidad de nodos colgantes (sin aristas de salida).



P 2 (Pregunta o hipótesis inicial (Motivación)). Formulen una pregunta inicial concreta que quieran responder usando PageRank.

La pregunta debe estar anclada en el contexto de la red elegida. Por ejemplo: «¿Qué artículos científicos son los más influyentes dentro de esta colección?» o «¿Cuáles son los usuarios más centrales e influyentes en esta red social?».

A continuación, propongan una hipótesis inicial sobre cuáles nodos esperan que obtengan mayor PageRank y por qué. La hipótesis debe basarse en conocimiento del dominio o en la exploración preliminar de los datos, **antes** de calcular el PageRank. Por ejemplo, podrían anticipar que los nodos con mayor grado de entrada tendrán mayor PageRank, o que ciertos nodos con posición estratégica en la red serán más influyentes de lo que su grado sugiere.

La salida esperada es un párrafo con la pregunta y un párrafo con la hipótesis inicial.

P 3 (Análisis exploratorio de la red). Realicen un análisis exploratorio de la red antes de calcular PageRank.

Como mínimo, incluyan:

- (a) Gráfico de la distribución del grado de entrada y del grado de salida.
- (b) Identificación y conteo de los nodos colgantes (nodos con grado de salida cero). Expliquen por qué su presencia es problemática para el PageRank y cómo se resuelve con la matriz columna-estocástica S .
- (c) Gráfico o tabla con los 10 nodos de mayor grado de entrada y los 10 nodos de mayor grado de salida. Si los nodos tienen nombres o etiquetas, inclúyanlos.
- (d) Comentario sobre si la red parece ser fuertemente conexa o si existen componentes aisladas. Pueden usar la condición de que la Matriz de Google G es siempre irreducible independientemente de la estructura del grafo subyacente.

P 4 (Construcción de la Matriz de Google). Construyan paso a paso la Matriz de Google G . Pueden seguir los siguientes pasos vistos en clase:

- (a) **Matriz de hipervínculos H** : Definan la matriz $H \in \mathbb{R}^{n \times n}$ con entradas

$$H_{ij} = \begin{cases} \frac{1}{\text{out}(j)} & \text{si } j \rightarrow i \\ 0 & \text{si no,} \end{cases}$$

donde $\text{out}(j)$ es el grado de salida del nodo j . Expliquen por qué cada columna de H suma a 1 cuando el nodo fuente no es colgante, y cómo identifican las columnas cero*.

*En la parte anterior reportaron cuántas columnas cero hay y qué fracción del total representan.



- (b) **Matriz columna-estocástica S :** Reparen los nodos colgantes reemplazando cada columna cero de H por el vector $\mathbf{1}/n$, de modo que

$$S = H + \frac{1}{n} \mathbf{a} \mathbf{1}^T,$$

donde $a_j = 1$ si el nodo j es colgante y 0 si no. Verifiquen que todas las columnas de S suman a 1.

- (c) **Matriz de Google G :** Construyan

$$G = \alpha S + \frac{1 - \alpha}{n} \mathbf{1} \mathbf{1}^T.$$

Justifiquen la elección del parámetro α que usarán y expliquen por qué todas las entradas de G son estrictamente positivas.

P 5 (Cálculo del PageRank mediante iteración de potencias). Implementen el algoritmo de iteración de potencias para calcular el PageRank (pueden usar la implementación vista en clase).

- (a) Comiencen desde el vector uniforme $\mathbf{r}^{(0)} = \mathbf{1}/n$ e iteren

$$\mathbf{r}^{(k+1)} = G \mathbf{r}^{(k)}$$

hasta que el error $\|\mathbf{r}^{(k+1)} - \mathbf{r}^{(k)}\|_1 < \varepsilon$, con $\varepsilon = 10^{-10}$. Reporten cuántas iteraciones fueron necesarias.

- (b) Grafiquen la curva de convergencia: el error $\|\mathbf{r}^{(k)} - \mathbf{r}^*\|_1$ en función de k , en escala logarítmica. Verifiquen que el decaimiento es geométrico con razón aproximada α .
- (c) Verifiquen que $\|\mathbf{r}^*\|_1 = 1$ y que $r_i^* > 0$ para todo i . Expliquen por qué estas dos propiedades están garantizadas por la teoría.
- (d) Presenten una tabla con los **20 nodos de mayor PageRank**, incluyendo su rango (top-1, top-2, ...), identificador (algún id, nombre o etiqueta proveniente de sus datos), PageRank (valor de r_i^*), grado de entrada y grado de salida.

P 6 (PageRank vs. grado de entrada). Comparen el PageRank con la centralidad de grado de entrada (es decir, el número de enlaces que apuntan a un nodo).

- (a) Grafiquen el grado de entrada vs. PageRank para todos los nodos (disperso, con los 10 nodos más importantes destacados). Calculen el coeficiente de correlación de Pearson entre ambas medidas.
- (b) Identifiquen al menos **dos nodos** para los cuales el PageRank y el grado de entrada difieren significativamente: un nodo con alto in-degree pero PageRank relativamente bajo, y un nodo con PageRank alto pero in-degree moderado.



P 7 (Interpretación de resultados). Interpreten los resultados del PageRank en el contexto de la red elegida.

- (a) Presenten los nodos de mayor PageRank y expliquen, usando conocimiento del dominio, por qué tienen sentido como nodos influyentes. Si los nodos tienen identificadores interpretables (nombre de usuario, título de artículo, URL, etc.), úsenlos en la discusión.
- (b) Visualicen el subgrafo inducido por los **30 a 50 nodos de mayor PageRank**. Los nodos deben estar escalados por PageRank y, si existen atributos de nodo (por ejemplo, categoría, tipo o comunidad), coloreen los nodos por ese atributo. Incluyan una leyenda y comenten la estructura observada.
- (c) Si la red tiene atributos de nodo o etiquetas naturales (por ejemplo, orientación política en redes de blogs, área temática en redes de citas, país en redes de comunicación), analicen si los nodos de mayor PageRank pertenecen a un grupo particular o si están distribuidos entre los grupos.

P 8 (Discusión, limitaciones y conclusiones). Comparen los resultados con la hipótesis inicial.

Indiquen si la hipótesis se cumplió o no, expliquen resultados esperados e inesperados, y discutan límites del método y de los datos. En particular, aborden las siguientes preguntas:

- ¿La pregunta que formularon quedó respondida con el análisis? ¿En qué medida?
- ¿Qué limitaciones tiene PageRank para la red elegida? Por ejemplo: ¿tiene sentido el modelo de marcha aleatoria? ¿los nodos colgantes son frecuentes y afectan el resultado? ¿la red es demasiado densa o demasiado dispersa para que PageRank sea informativo?
- ¿Qué preguntas nuevas surgieron del análisis que no anticiparon al comienzo?
- Si tuvieran que explicar el resultado principal a alguien sin conocimientos técnicos, ¿cómo lo describirían?

Checklist mínimo de entrega

La entrega debe incluir, al menos:

- red elegida descrita con fuente citada y tabla de estadísticas básicas;
- pregunta e hipótesis inicial documentadas;
- análisis exploratorio de la red con gráficos de distribución de grado;
- construcción explicitada de H , S y G (en su código);



- implementación propia de la iteración de potencias con curva de convergencia;
- tabla de los 20 nodos de mayor PageRank;
- comparación PageRank vs. grado de entrada con gráfico y correlación;
- visualización del subgrafo de los nodos más importantes;
- discusión final que conecte con la hipótesis inicial;
- código reproducible en GitHub.

Pauta general de evaluación

- **Elección y descripción de la red (15 %):** red bien elegida, con contexto claro y estadísticas básicas correctas.
- **Pregunta e hipótesis (10 %):** pregunta concreta y relevante, hipótesis inicial justificada.
- **Construcción de la Matriz de Google (20 %):** H , S y G bien definidas, manejo correcto de nodos colgantes, implementación eficiente de la multiplicación matriz-vector (usar librerías).
- **Cálculo e interpretación del PageRank (25 %):** iteración de potencias correcta, análisis de convergencia, análisis de α , comparación con grado de entrada, e interpretación en contexto.
- **Claridad del informe (15 %):** redacción clara, ordenada y precisa; figuras con ejes y leyendas correctas.
- **Reproducibilidad del código (15 %):** repositorio ordenado, ejecutable, y suficiente para reproducir el trabajo.

Entrega ideal

Una entrega bien lograda debería mostrar que la red está bien explicada y su elección justificada, que la pregunta es concreta y que la hipótesis inicial se conecta con el análisis posterior. La Matriz de Google debería construirse paso a paso con comprensión matemática real, no como una caja negra. La iteración de potencias debería implementarse de forma eficiente, con una curva de convergencia que ilustre la tasa geométrica con razón α . La comparación con el grado de entrada debería mostrar que PageRank no es simplemente un conteo de enlaces, sino que captura la «relevancia» recursiva de los nodos. La visualización del subgrafo de los nodos más importantes debería revelar la estructura de la red de forma clara. Finalmente, la discusión debe ser crítica: debe decir con honestidad qué funcionó, qué no funcionó y por qué, y debe responder directamente a la pregunta planteada al inicio (debe haber coherencia con el inicio).